

Lien Google Drive : https://drive.google.com/drive/folders/1Ut0-9HuR4YpV2_tNcE4X6mVhTnsRlppt?usp=share_link

PROJET HADOOP

Analyse des accidents de moto en France
(2015-2024)

Étudiant : RONDEAU Arthur

Formation : Master 1 – Informatique Big Data

Date de rendu : 5 Janvier 2025

1. OBJECTIF DU PROJET

Développer une application Hadoop pour analyser les données d'accidents de la route en France sur 10 ans (2015-2024), avec un focus particulier sur accidents impliquant des motos et scooters. L'objectif d'identifier les facteurs de risque, les profils et les conditions des victimes, d'accidents les plus dangereuses les motards. pour

2. SOURCES DE DONNÉES

Source: Open Data du gouvernement français (data.gouv.fr)
Bases de données annuelles des accidents corporels de la circulation routière

Fichier	Descrip+on	Volume
caracteris+ques-YYYY.csv	Circonstances : date, heure, localisation, météo	~60k lignes/an
vehicules-YYYY.csv	Véhicules impliqués : catégorie, manœuvre, choc	~95k lignes/an
usagers-YYYY.csv	Personnes impliquées : âge, gravité blessures	~127k lignes/an
lieux-YYYY.csv	Infrastructure : type de route, tracé, profil	~60k lignes/an

Volume total : 4 Fichiers par année, donc 40
 Fichiers CSV (~5 millions de lignes) couvrant 10
 années de données.

3. TECHNOLOGIES HADOOP UTILISÉES

Technologie	U+lis+on
HDFS	Stockage distribué des 40 Fichiers CSV
MapReduce	Traitement parallèle des millions de lignes de données
YARN	Gestion des ressources et orchestration des jobs
Hive	Création de tables et requêtes SQL (HQL)

Infrastructure : Installation locale macOS (Mac M1) avec Hadoop
 en mode pseudodistribué

4. DÉFIS TECHNIQUES RENCONTRÉS

Le projet a nécessité de surmonter plusieurs obstacles techniques majeurs, principalement à l'hétérogénéité des formats de Fichiers sur 10 aux incompatibilités années et logicielles.

4.1 Formats de fichiers multiples

Problème : Les Fichiers ont changé de format gouvernementaux entre 2015 et 2024

Période	Format	Particularités
2015, 2017-2018	Virgule, sans guillemets	16 colonnes
2016	Virgule, sans guillemets	17 colonnes (1 en +)
2019-2020	Point-virgule, guillemets	Structure intermédiaire
2021-2024	Point-virgule, guillemets	Colonnes supplémentaires

Solution : Création de tables Hive multiples (caracteristiques_old, caracteristiques_2016, caracteristiques_new) avec adaptées, puis fusion UNION ALL. via structures

4.2 Incompatibilités Java

Problème : Java 23 incompatible avec Hadoop 3.4.2 (erreur

UnsupportedOperationException). Java 11 incompatible avec Hive 2.3.9.

Solution : Installation de Java 8 pour compatibilité complète.

4.3 Décalages de colonnes

Problème : Fichiers usagers 2019-2020 sans id_usager (15 colonnes) vs 2021-2024 avec id_usager (16 colonnes).
Décalage de toutes colonnes lors du parsing.
les

Solution : Création de 3 tables usagers (usagers_old, usagers_mid, usagers_new) avec structures exactes.

4.4 Échec VM Google Cloud

Problème : VM en Safe Mode HDFS, DataNode instable, ressources limitées.

Solution : Migration vers environnement local macOS pour meilleur contrôle stabilité.
et

5. ARCHITECTURE DISTRIBUÉE

5.1 Pipeline de traitement

- 1. Ingestion : Upload des 40 Fichiers CSV dans HDFS
- 2. Structuration : Création de 12 tables Hive externes
- 3. UniFication : Fusion via UNION ALL en 4 tables Finales
- 4. Traitement : Exécution de 8 requêtes HQL → jobs MapReduce
- 5. Jointures : caractéristiques ↔ vehicules ↔ usagers ↔ lieux
- 6. Export : Résultats en CSV pour visualisation Python

5.2 Justification Hadoop

Le volume (~5M lignes) et la complexité des jointures avec formats hétérogènes justifient Hadoop. Le traitement parallèle via MapReduce et la scalabilité HDFS garantissent performances optimales. Sans Hadoop, le traitement prendrait plusieurs heures au lieu de quelques minutes.

6. ANALYSES RÉALISÉES

Analyse	Objet+f	Résultat clé
Évolu+on temporelle	Accidents 2015-2024	Baisse 25% (21k→16k)
Géographie	Top 20 départements	Paris: 15k, Aisne: 15k
Météo	Impact conditions	Enblouissement: 7.93%
Profils vic+mes	Tranches d'âge	65+ ans: 7.06%
Moments cri+ques	Heures dangereuses	Nuit: 7.21%
Collisions	Types accidents	Frontale: 9%
Infrastructure	Tracé route	Plat+Rectiligne: 132k
Cylindrées	Motos vs scooters	>125cc: 5.73%

Total : 8 requêtes HQL exécutées, 8 Fichiers CSV, 8 graphiques Python.

7. RÉSULTATS

7.1 Facteurs de risque majeurs

- Age : Seniors 65+ risque 2.2x supérieur (7.06% avec 3.19%)
- Horaire : Nuit 2.4x plus mortel que matin (7.21% vs 2.99%)
- Collision : Frontale 4.2x plus mortel que latérale (9% vs 2.16%)
- Véhicule : >125cc 4x plus mortel que <50cc (5.73% vs 1.43%)
- Météo : Enblouissement plus mortel (7.93% vs 3.89%)

7.2 Tendances temporelles

Baisse continue -25% (2015→2024). Chute COVID en 2020 (-21% vs 2019). Rebond 2021 puis stabilisation 16-17k victimes/an. Suggère efficacité des politiques de prévention.

8. VISUALISATIONS

8 graphiques créés avec Python (Matplotlib/Pandas) à partir des résultatsHive. visualisations facilitent l'interprétation des Les tendances et communication des insights. la

- Evolution 2015-2024 : Graphique linéaire de la baisse des victimes
- Top 10 départements : Barres horizontales des zones à risque
- Impact météo : Taux de mortalité selon conditions
- ProFils par âge : Double graphique+ (victimes mortalité)
- Répartition horaire: Barres colorées par plage
- Types de collision : Dangersité par type
- Conditions : Top 10 configurations route
- Cylindrées : Double axe (volume + mortalité)

9. CONCLUSION

Ce projet a permis d'analyser avec succès 10 années de données d'accidents de moto en France, représentant de 186 000 victimes. L'utilisation de plus l'écosystème (HDFS, MapReduce, Hive) s'est avérée essentielle Hadoop pour traiter ce volume de données hétérogènes. efficacement

Les défis techniques rencontrés (formats multiples, incompatibilités logicielles, décalages de colonnes) ont nécessité une approche méthodique et des solutions architecturales créatives. Cette expérience illustre la réalité des projets

Big Data : les données réelles sont rarement propres, et la majorité du temps est consacrée au nettoyage plutôt qu'à l'analyse.

Les analyses révèlent des facteurs de risque clairs et quantifiables qui peuvent guider les politiques de prévention : âge avancé, conduite nocturne, collisions frontales, grosses cylindrées, éblouissement.

Perspectives d'amélioration

- Analyse prédictive avec machine learning (Random Forest, XGBoost)
- Cartographie interactive des zones à risque
- Extension à d'autres véhicules (vélos, trottinettes)

Compétences développées

- Architecture distribuée Hadoop (HDFS, MapReduce, YARN)

- Requêtes HQL complexes avec jointures multiples
- Gestion de données hétérogènes et multiformats
- Debugging système résolution d'incompatibilités
et
- Visualisation de données avec Python