

PROJET HADOOP

Analyse des accidents de moto en France (2015-2024)

Étudiant : RONDEAU Arthur
Formation : Master 1 - Informatique Big Data
Date de rendu : 5 Janvier 2025

1. OBJECTIF DU PROJET

Développer une application Hadoop pour analyser les données d'accidents de la route en France sur 10 ans (2015-2024), avec un focus particulier sur les accidents impliquant des motos et scooters. L'objectif est d'identifier les facteurs de risque, les profils des victimes, et les conditions d'accidents les plus dangereuses pour les motards.

2. SOURCES DE DONNÉES

Source : Open Data du gouvernement français (data.gouv.fr) - Bases de données annuelles des accidents corporels de la circulation routière

Fichier	Description	Volume
caracteristiques-YYYY.csv	Circonstances : date, heure, localisation, météo, luminosité	~80k lignes/an
vehicules-YYYY.csv	Véhicules impliqués : catégorie, manœuvre, choc	~150k lignes/an
usagers-YYYY.csv	Personnes impliquées : âge, gravité blessures, équipements	~200k lignes/an
lieux-YYYY.csv	Infrastructure : type de route, tracé, profil, surface	~80k lignes/an

Volume total : 4 fichiers par année, donc 40 fichiers CSV (~5 millions de lignes) couvrant 10 années de données.

3. TECHNOLOGIES HADOOP UTILISÉES

Technologie	Utilisation
HDFS	Stockage distribué des 40 fichiers CSV dans une architecture répartie
MapReduce	Traitement parallèle des millions de lignes de données
YARN	Gestion des ressources et orchestration des jobs

Technologie	Utilisation
Hive	Création de tables et exécution de requêtes SQL (HQL) pour l'analyse

Infrastructure : Google Cloud Platform - VM avec cluster Hadoop (déjà utilisée en TP)

4. ANALYSES PRÉVUES AVEC HIVE

Analyse	Objectif
Évolution temporelle	Nombre d'accidents moto par année (2015-2024), tendances
Géographie des risques	Top 20 départements avec le plus d'accidents mortels
Impact météorologique	Corrélation entre conditions météo et gravité des accidents
Profils des victimes	Répartition par tranches d'âge et taux de mortalité
Moments critiques	Heures et mois de la journée les plus dangereux
Types de collision	Analyse des circonstances (frontale, latérale, sans collision)
Infrastructure routière	Impact du tracé (virages, lignes droites) et du profil (pentes)
Catégories de véhicules	Comparaison scooters vs motos, petites vs grosses cylindrées

5. ARCHITECTURE DISTRIBUÉE

- **Ingestion** : Upload des 40 fichiers CSV dans HDFS (répartition en blocs sur le cluster)
- **Structuration** : Création de 4 tables Hive externes pointant vers les répertoires HDFS
- **Traitement** : Exécution de requêtes HQL transformées en jobs MapReduce par Hive
- **Analyse** : Jointures entre tables (caracteristiques ↔ vehicules ↔ usagers ↔ lieux)
- **Export** : Résultats exportés en CSV pour visualisation (graphiques, tableaux)

Justification de l'utilisation d'Hadoop : Le volume de données (plusieurs millions de lignes) et la complexité des jointures entre 4 tables nécessitent une infrastructure distribuée. Hadoop permet de traiter ces données en parallèle et de garantir la scalabilité du système.